

# Predicción de Burnout en Desarrolladores

Calidad de Datos · Mitigación de Sesgos · Explicabilidad XAI

## Grupo 4

- › Eduardo Ceballos Jijón
- › Guillermo Granizo Veintimilla
- › José Ulloa Manzur
- › Christian Valle Maridueña

**7,000**

Registros

**10**

Variables predictoras

**Ridge**

Modelo

**$R^2 = 0.81$**

Rendimiento

**RMSE = 10.17**

Error test

**5 técnicas**

XAI

# INTRODUCCIÓN DEL PROBLEMA

¿Qué es el Burnout en desarrolladores y por qué predecirlo?



## El Problema

El burnout laboral afecta a una proporción significativa de los desarrolladores globalmente. Su detección tardía genera rotación, errores críticos y problemas de salud.



## El Objetivo


Predecir el nivel de estrés (0–100) de un desarrollador usando métricas de comportamiento laboral: horas de trabajo, bugs, sueño, reuniones y cafeína.



## El Dataset

7,000 registros × 12 columnas — 10 variables predictoras tras eliminar el target y el leakage. Variable objetivo: stress\_level (continua). Tipo: REGRESIÓN.

Distribución de stress\_level (variable objetivo)




## DATA LEAKAGE Detectado

**burnout\_level** = discretización DETERMINÍSTICA de **stress\_level**  
Low=[0–35] | Medium=[35–70] | High=[70–100]  
→ Genera leakage perfecto. Eliminada del modelo antes de cualquier paso.

# METODOLOGÍA Y TÉCNICAS APLICADAS

Flujo obligatorio: Limpiar → Eliminar Leakage → Split → Imputar → Escalar → Modelo

## Pipeline Unificado — Flujo Obligatorio del Notebook



### Por qué Ridge Regression

Relaciones lineales dominantes ( $r=0.60$  para `daily_work_hours`). Regularización L2 maneja multicolinealidad. Interpretable directamente por coeficientes.

### Por qué 80/20 estratificado

6,860 registros válidos → 5,488 train y 1,372 test. Estratificado por rango de estrés garantiza representatividad en ambos conjuntos.

### Por qué Winsorizer P5–P95

Outliers plausibles del dominio (14h trabajo, 4h sueño). P5–P95 más conservador que IQR. Encapsulado en Pipeline: fit solo en train.

### Por qué `np.clip(0, 100)`

Ridge puede predecir fuera del rango físico [0–100]. 19 predicciones fuera de rango en test (min: -3.9, max: 120.2). Clip garantiza predicciones válidas.

# ANÁLISIS DEL MODELO

Ridge Regression — Alpha óptimo = 1.0 (GridSearchCV 5-fold) | Predicciones con np.clip(0,100)

10.17

RMSE test

7.99

MAE test

0.81

$R^2$  test


0.50%

Gap train→test


56.7%

Mejora vs baseline


Residuales vs Predicción



Distribución de residuales



GridSearchCV — Optimización de Alpha (Ridge)



## CV 5-Fold — RMSE por fold



Fold 1: 10.03 | Fold 2: 10.31 | Fold 3: 10.11

Fold 4: 10.28 | Fold 5: 10.09

Promedio: 10.17 ± 0.11

# TRANSPARENCIA DEL MODELO

5 Técnicas XAI aplicadas — consistencia validada entre métodos independientes



## Coeficientes Ridge

Interpretación directa. `daily_work_hours` = 27.1% del peso total del modelo.

## Permutation Importance

Al permutar `daily_work_hours` el RMSE aumenta +10.31 pts (35.2% del impacto total).

## Partial Dependence Plots

Relación marginal por variable. Efecto lineal confirmado en las 4 variables principales.

## SHAP (Shapley Values)


Explicación exacta por predicción individual. Global (beeswarm) + local (waterfall).

## LIME

Aproximación local con fidelidad variable:  $R^2 \approx 0.07\text{--}0.59$  por instancia. Contrasta con SHAP exacto.

# EQUIDAD ALGORÍTMICA (FAIRNESS)

$\Delta$  RMSE  $\approx$  1.03 pts para jornada y 0.48 pts para edad — ambos menores al umbral de 3 pts



## Por jornada laboral

Normal: 10.53 | Alta: 10.36 | Extrema: 9.52  
 $\Delta$  RMSE = 1.02 pts (< 3 pts)

## Por edad

Junior: 10.48 | Mid: 9.93 | Senior: 10.08  
 $\Delta$  RMSE = 0.54 pts (< 3 pts)

## Mitigación activa

Ablación de 'age':  $\Delta$ RMSE = -0.0035 pts  
Decisión: mantener age (impacto insignificante).




**Criterio de equidad:  $\Delta$  RMSE < 3 puntos entre grupos = modelo equitativo**

Grupos validados: 3 grupos de jornada (478/460/434 registros) y 3 grupos de edad (463/474/432 registros). Ninguna subpoblación experimenta error sistemáticamente mayor al umbral establecido.

# RIESGOS ÉTICOS Y SOCIALES

Si este modelo se implementa en una organización real sin controles adecuados...



## Vigilancia encubierta

Monitoreo continuo sin consentimiento viola privacidad y autonomía del trabajador.

## Uso punitivo

Predicción de estrés alto usada para decisiones de RRHH en vez de apoyo al empleado.

## Falsa objetividad

Un número (ej: 74) percibido como certeza. Error promedio del modelo:  $\pm 10$  pts.

## Goodhart's Law

Desarrolladores modifican comportamiento reportado para 'parecer menos estresados'.

## Degradación temporal

Modelo estático en entorno dinámico pierde precisión en 12–18 meses.

LOPDP Ecuador: los sistemas automatizados que afectan a personas deben explicar sus decisiones (transparencia, trazabilidad). Sin explicabilidad, el sistema puede incumplir la ley.

# REFLEXIÓN CRÍTICA

Tres preguntas esenciales sobre el modelo y sus implicaciones

## 01

¿Qué aprendizaje desarrolló sobre cómo el modelo toma decisiones?

El modelo aprendió que el estrés es función de CONDICIONES LABORALES, no del individuo.

✅ Sí importa: horas trabajo ( $r=0.60$ , 27.1%), bugs/día (24.4%), reuniones (17.3%), sueño (11.7%)

❌ NO importa: edad ( $r=0.006$ , 0.43%), experiencia ( $r=-0.020$ , 0.32%), commits (0.11%)

→ Un senior con 15 años de experiencia puede tener estrés BAJO si trabaja jornadas razonables. La responsabilidad de intervención es de la ORGANIZACIÓN.

## 02

¿Hay alguna variable que tenga un peso excesivo?

daily\_work\_hours domina pero no monopoliza:

- Coeficientes Ridge: 27.1% del peso total
- Permutation Importance ( $\Delta RMSE$ ): +10.31 pts (35.2% del impacto)

Las 3 variables top concentran el 68.8% del peso — distribución razonable.

Riesgo: Goodhart's Law. Si el developer sabe que sus horas son lo más importante, puede modificar lo que reporta sin cambiar su estrés real.

## 03

¿Qué pasaría si este modelo se implementa sin explicabilidad?

❌ SIN explicabilidad → Caja negra:  
"El modelo predice estrés alto." — ¿Por qué?  
Desconocido.  
Sin detección de sesgos. Sin base para apelar. Riesgo legal LOPDP Ecuador.

✅ CON SHAP → Acción concreta:  
"+23 pts: trabaja 13h/día | +19 pts: 12 bugs/día | -4 pts: hace ejercicio"  
→ Intervención específica, trazable y auditable.



# CONSIDERACIONES PARA MEJORAR EL MODELO

Cuatro líneas de mejora identificadas a partir del análisis del notebook

01

## Variables de Contexto

- › Tipo de proyecto (legacy vs. nuevo)
- › Tamaño del equipo (solo vs. colaborativo)
- › Modalidad (remoto vs. presencial)
- › Claridad de requisitos del sprint

*Capturar factores organizacionales que expliquen parte del 19% de varianza no capturada.*

02

## Dimensión Temporal

- › Estrés acumulado en semanas consecutivas
- › Modelos LSTM o Prophet para series temporales
- › Tendencias que Ridge no puede detectar
- › Alertas antes de que el burnout sea severo

*El estrés puntual vs. estrés acumulado tienen distinto nivel de riesgo real.*

03

## Validación con Datos Reales

- › Dataset actual es SINTÉTICO (Kaggle)
- › Encuestas de bienestar real de empleados
- › Ajustar umbrales a percepción subjetiva real
- › Validar que  $R^2=0.81$  se mantiene en producción

*Un modelo entrenado en datos sintéticos puede no generalizar al mundo real.*

04

## Retroalimentación en Producción

- › Registrar resultado de cada intervención de RRHH
- › Aprender qué intervenciones son efectivas
- › Reentrenar cada 6 meses con datos reales
- › Monitorear RMSE en producción continuamente

*Un modelo estático en un entorno dinámico pierde precisión inevitablemente.*

# CONCLUSIONES Y RECOMENDACIONES

## Conclusiones

1. Ridge Regression ( $\alpha=1.0$ ) logra  $R^2=0.81$  con RMSE=10.17 pts — supera el baseline en 56.7%.

2. Gap train $\leftrightarrow$ test de 0.50% — modelo sin overfitting, robusto y generalizable.

3. El estrés es determinado por condiciones laborales, no por perfil del desarrollador.

4. Equidad verificada:  $\Delta$  RMSE  $\approx$  1.03 pts jornada y 0.48 pts edad (ambos  $< 3$  pts).

5. 5 técnicas XAI con consistencia validada: SHAP, LIME ( $R^2 \approx 0.07-0.59$ ), PDP, Coef., Perm. Imp.

## Recomendaciones

Uso como alerta temprana, no como diagnóstico médico. Supervisión humana obligatoria en toda decisión.

Consentimiento informado de todos los empleados y comunicación transparente del propósito.

Reentrenamiento semestral y monitoreo del RMSE en producción para detectar degradación.

Añadir variables de contexto organizacional y dimensión temporal (LSTM/Prophet).

Validar con datos reales (no sintéticos) antes de cualquier despliegue productivo.

# Predicción de Burnout en Desarrolladores

Calidad de Datos · Mitigación de Sesgos · Explicabilidad

## Grupo 4

- › Eduardo Ceballos Jijón
- › Guillermo Granizo Veintimilla
- › José Ulloa Manzur
- › Christian Valle Maridueña