

Predicción de Burnout en Desarrolladores

Calidad de Datos · Mitigación de Sesgos · Explicabilidad

Grupo 4

- › Eduardo Ceballos Jijón
- › Guillermo Granizo Veintimilla
- › José Ulloa Manzur
- › Christian Valle Maridueña

7,000

Registros

10

Variables

Ridge

Modelo

$R^2 = 0.81$

Rendimiento

RMSE = 10.21

Error test

5 técnicas

XAI

INTRODUCCIÓN DEL PROBLEMA

¿Qué es el Burnout en desarrolladores y por qué predecirlo?



El Problema

El burnout laboral afecta al 52% de los desarrolladores globalmente. Su detección tardía genera rotación, errores críticos y problemas de salud.



El Objetivo


Predecir el nivel de estrés (0–100) de un desarrollador usando métricas de comportamiento laboral como horas de trabajo, bugs y sueño.



El Dataset

7,000 registros × 12 variables del Kaggle Developer Burnout Prediction Dataset. Variable objetivo: stress_level (continua). Tipo: REGRESIÓN.

Distribución de stress_level (variable objetivo)



DATA LEAKAGE Detectado

burnout_level = discretización determinista de **stress_level**
Low=[0–35] | Medium=[35–70] | High=[70–100]
Correlación 1.0 con el target → Eliminada del modelo.

METODOLOGÍA Y TÉCNICAS APLICADAS

Flujo obligatorio: Limpiar → Eliminar Leakage → Split → Imputar → Encoding → Scaling

Flujo Obligatorio del Notebook — Pipeline Unificado



Por qué Ridge Regression

Relaciones principalmente LINEALES ($r=0.60$ para `daily_work_hours`). La regularización L2 maneja multicolinealidad. Interpretable por coeficientes directos.

Por qué Winsorizing P5–P95

Outliers plausibles en dominio real (14h trabajo, 4h sueño). P5–P95 más conservador que IQR. Encapsulado en Pipeline → fit solo en train.

Por qué 80/20 Split

Con 6,860 registros, el 20% de test = 1,372 muestras suficientes para estimación robusta. Estratificado por rango de estrés (Bajo/Medio/Alto).

Por qué SimpleImputer(mean)

Skewness $|\lt 1|$ en todas las features → distribuciones simétricas → media = estimador de mínima varianza. 140 nulos/columna (2%).

ANÁLISIS DEL MODELO

Ridge Regression — Alpha óptimo = 1.0 (GridSearchCV 5-fold)

10.21

RMSE test

8.06

MAE test

0.81



R^2 test

0.54%

Gap train→test

56.5%

Mejora vs baseline





CV 5-Fold — RMSE por fold

Fold 1: 10.03 | Fold 2: 10.31 | Fold 3: 10.12

Fold 4: 10.28 | Fold 5: 10.09 | Promedio: 10.17 ± 0.11

TRANSPARENCIA DEL MODELO

5 Técnicas de Explicabilidad (XAI) aplicadas — consistencia validada



Coeficientes Ridge

Interpretación directa. `daily_work_hours` = 27.1% del peso total.

Permutation Importance

Impacto real en RMSE: `daily_work_hours` reduce RMSE en 316.87 pts.

Partial Dependence Plots

Relación marginal por variable. Efecto lineal confirmado.

SHAP (Shapley Values)


Explicación exacta por predicción individual. Global + local.

LIME

Aproximación lineal local. Fidelidad validada (R^2 local > 0.60).

EQUIDAD ALGORÍTMICA (FAIRNESS)

El modelo comete errores similares para todos los grupos — $\Delta \text{RMSE} < 1$ pt en ambas dimensiones



Por jornada laboral

Normal: 10.60 | Alta: 10.12 | Extrema: 9.66
 $\Delta \text{RMSE} = 0.94$ pts ✓

Por edad

Junior: 10.52 | Mid: 10.00 | Senior: 10.16
 $\Delta \text{RMSE} = 0.52$ pts ✓



Criterio de equidad: $\Delta \text{RMSE} < 3$ puntos entre grupos = modelo equitativo


Grupos validados con distribución real: 3 grupos de jornada (444/456/443 registros) y 3 grupos de edad (463/454/432 registros). Ninguna subpoblación experimenta error sistemáticamente mayor.

Mitigación activa

Ablación de 'age': $\Delta \text{RMSE} = -0.003$ pts
Decisión: mantener age (impacto mínimo).

RIESGOS ÉTICOS Y SOCIALES

Si este modelo se implementa en una organización real sin controles adecuados...



Vigilancia encubierta

Monitoreo continuo sin consentimiento viola privacidad y autonomía del trabajador.

Uso punitivo

Predicción de estrés alto usada para decisiones de RRHH en vez de apoyo al empleado.

Falsa objetividad

Un número (ej: 74) percibido como certeza. Error promedio = ± 10 pts.

Goodhart's Law

Desarrolladores modifican comportamiento reportado para 'parecer menos estresados'.

Degradación temporal

Modelo entrenado hoy puede ser inexacto en 12–18 meses. Requiere reentrenamiento.

LOPDP Ecuador: sistemas automatizados que afecten a personas deben explicar sus decisiones (transparencia, trazabilidad). Sin explicabilidad, el sistema puede incumplir la ley.

REFLEXIÓN CRÍTICA

Tres preguntas esenciales sobre el modelo y sus implicaciones

01

¿Qué aprendió el modelo sobre cómo toma decisiones?

El modelo aprendió que el estrés es función de CONDICIONES LABORALES, no del individuo.

✓ Sí importa: horas trabajo ($r=0.60$), bugs/día, reuniones, sueño, cafeína
✗ NO importa: edad ($r=0.006$), experiencia ($r=-0.020$), commits ($r=-0.008$)

→ Un senior con 15 años de experiencia puede tener estrés BAJO si trabaja jornadas razonables. La responsabilidad de intervención es de la ORGANIZACIÓN.

02

¿Hay alguna variable con peso excesivo?

daily_work_hours domina pero no en exceso:

- Coeficientes Ridge: 27.1% del peso total
- Permutation Importance: 35.2% del impacto en RMSE

No concentra sola la decisión. Las 3 variables top (daily_work_hours + bugs + meetings) explican el 68.8% del peso total, lo que indica distribución razonable.

03

¿Qué pasaría si este modelo se implementa sin explicabilidad?

✗ SIN explicabilidad → Caja negra:
• "El modelo predice estrés alto." — ¿Por qué? Desconocido.

- Sin detección de sesgos. Sin base para apelación.
- Riesgo legal LOPDP Ecuador.

✓ CON SHAP → Acción concreta:
"+23 pts: trabaja 13h diarias | +19 pts: 12 bugs/día | -4 pts: hace ejercicio"
→ Permite intervención específica y trazable.

CONSIDERACIONES PARA MEJORAR EL MODELO

Cuatro líneas de mejora identificadas a partir del análisis del notebook

01

Variables de Contexto

- › Tipo de proyecto (legacy vs nuevo)
- › Tamaño del equipo (solo vs colaborativo)
- › Modalidad (remoto vs presencial)
- › Claridad de requisitos del sprint

Capturar factores organizacionales que el modelo actual no puede ver.

02

Dimensión Temporal

- › Estrés acumulado en semanas consecutivas
- › Modelos de series temporales: LSTM, Prophet
- › Tendencias que Ridge no puede detectar
- › Alertas antes de que el burnout sea severo

El estrés puntual vs. estrés acumulado = diferente nivel de riesgo real.

03

Validación con Datos Reales

- › Dataset actual es SINTÉTICO (Kaggle)
- › Encuestas de bienestar real de empleados
- › Ajustar umbrales Bajo/Medio/Alto a percepción subjetiva
- › Validez de constructo del modelo

Un modelo entrenado en datos sintéticos puede no generalizar al mundo real.

04

Retroalimentación del Modelo

- › Cuando RRHH interviene y estrés baja: registrar el resultado
- › Aprender qué intervenciones son efectivas
- › Reentrenar cada 6 meses con datos nuevos
- › Monitorear RMSE en producción continuamente

Un modelo estático en un entorno dinámico pierde precisión inevitablemente.

CONCLUSIONES Y RECOMENDACIONES

Conclusiones

1. Ridge Regression logra $R^2=0.81$ con $RMSE=10.21$ pts — supera el baseline en 56.5%.

2. Gap train↔test de solo 0.54% — modelo sin overfitting, robusto y generalizable.

3. El estrés es determinado por condiciones laborales, no por perfil del desarrollador.

4. Equidad verificada: $\Delta RMSE < 1$ pt entre grupos de jornada y edad.

5. 5 técnicas XAI aplicadas con consistencia validada: SHAP, LIME, PDP, Permutation Importance y Coeficientes.

Recomendaciones

Uso como alerta temprana, no como diagnóstico médico. Supervisión humana obligatoria en toda decisión.

Consentimiento informado de todos los empleados y comunicación transparente del propósito.

Reentrenamiento semestral y monitoreo del RMSE en producción para detectar degradación.

Añadir variables de contexto organizacional y dimensión temporal (LSTM/Prophet).

Validar con datos reales (no sintéticos) antes de cualquier despliegue productivo.