

Predicción de Burnout en Desarrolladores

Calidad de Datos · Mitigación de Sesgos · Explicabilidad XAI

Grupo 4

- › Eduardo Ceballos Jijón
- › Guillermo Granizo Veintimilla
- › José Ulloa Manzur
- › Christian Valle Maridueña

7,000

Registros

10

Variables predictoras

Ridge

Modelo

$R^2 = 0.81$

Rendimiento

RMSE = 10.17

Error test

5 técnicas

XAI

INTRODUCCIÓN DEL PROBLEMA

¿Qué es el Burnout en desarrolladores y por qué predecirlo?



El Problema

El burnout laboral afecta a una proporción significativa de los desarrolladores globalmente. Su detección tardía genera rotación, errores críticos y problemas de salud.



El Objetivo


Predecir el nivel de estrés (0–100) de un desarrollador usando métricas de comportamiento laboral: horas de trabajo, bugs, sueño, reuniones y cafeína.



El Dataset

7,000 registros × 12 columnas — 10 variables predictoras tras eliminar el target y el leakage. Variable objetivo: stress_level (continua). Tipo: REGRESIÓN.

Distribución de stress_level (variable objetivo)




DATA LEAKAGE Detectado

burnout_level = discretización DETERMINÍSTICA de **stress_level**
Low=[0–35] | Medium=[35–70] | High=[70–100]
→ Genera leakage perfecto. Eliminada del modelo antes de cualquier paso.

METODOLOGÍA Y TÉCNICAS APLICADAS

Flujo obligatorio: Limpiar → Eliminar Leakage → Split → Imputar → Escalar → Modelo

Pipeline Unificado — Flujo Obligatorio del Notebook



Por qué Ridge Regression

Relaciones lineales dominantes ($r=0.60$ para `daily_work_hours`). Regularización L2 maneja multicolinealidad. Interpretable directamente por coeficientes.

Por qué 80/20 estratificado

6,860 registros válidos → 5,488 train y 1,372 test. Estratificado por rango de estrés garantiza representatividad en ambos conjuntos.

Por qué Winsorizer P5-P95

Outliers plausibles del dominio (14h trabajo, 4h sueño). P5-P95 más conservador que IQR. Encapsulado en Pipeline: fit solo en train.

Por qué `np.clip(0, 100)`

Ridge puede predecir fuera del rango físico [0–100]. 19 predicciones fuera de rango en test (min: -3.9, max: 120.2). Clip garantiza predicciones válidas.

ANÁLISIS DEL MODELO

Ridge Regression — Alpha óptimo = 1.0 (GridSearchCV 5-fold) | Predicciones con `np.clip(0,100)`

10.17

RMSE test

7.99

MAE test

0.81

R^2 test


0.50%

Gap train→test


56.7%

Mejora vs baseline


Residuales vs Predicción



Distribución de residuales



GridSearchCV — Optimización de Alpha (Ridge)



CV 5-Fold — RMSE por fold



Fold 1: 10.03 | Fold 2: 10.31 | Fold 3: 10.11

Fold 4: 10.28 | Fold 5: 10.09

Promedio: 10.17 ± 0.11

TRANSPARENCIA DEL MODELO

5 Técnicas XAI aplicadas — consistencia validada entre métodos independientes



Coeficientes Ridge

Interpretación directa. `daily_work_hours` = 27.1% del peso total del modelo.

Permutation Importance

Al permutar `daily_work_hours` el RMSE aumenta +10.31 pts (35.2% del impacto total).

Partial Dependence Plots

Relación marginal por variable. Efecto lineal confirmado en las 4 variables principales.

SHAP (Shapley Values)


Explicación exacta por predicción individual. Global (beeswarm) + local (waterfall).

LIME

Aproximación local con fidelidad variable: $R^2 \approx 0.07-0.59$ por instancia. Contrasta con SHAP exacto.

EQUIDAD ALGORÍTMICA (FAIRNESS)

Δ RMSE $\approx$ 1.03 pts para jornada y 0.48 pts para edad — ambos menores al umbral de 3 pts



Por jornada laboral

Normal: 10.53 | Alta: 10.36 | Extrema: 9.52
 Δ RMSE = 1.02 pts (< 3 pts)

Por edad

Junior: 10.48 | Mid: 9.93 | Senior: 10.08
 Δ RMSE = 0.54 pts (< 3 pts)

Mitigación activa

Ablación de 'age': Δ RMSE = -0.0035 pts
Decisión: mantener age (impacto insignificante).




Criterio de equidad: Δ RMSE < 3 puntos entre grupos = modelo equitativo

Grupos validados: 3 grupos de jornada (478/460/434 registros) y 3 grupos de edad (463/474/432 registros). Ninguna subpoblación experimenta error sistemáticamente mayor al umbral establecido.

RIESGOS ÉTICOS Y SOCIALES

Si este modelo se implementa en una organización real sin controles adecuados...



Vigilancia encubierta

Monitoreo continuo sin consentimiento viola privacidad y autonomía del trabajador.

Uso punitivo

Predicción de estrés alto usada para decisiones de RRHH en vez de apoyo al empleado.

Falsa objetividad

Un número (ej: 74) percibido como certeza. Error promedio del modelo: ± 10 pts.

Goodhart's Law

Desarrolladores modifican comportamiento reportado para 'parecer menos estresados'.

Degradación temporal

Modelo estático en entorno dinámico pierde precisión en 12–18 meses.



LOPD Ecuador: los sistemas automatizados que afecten a personas deben explicar sus decisiones (transparencia, trazabilidad). Sin explicabilidad, el sistema puede incumplir la ley.

REFLEXIÓN CRÍTICA

Tres preguntas esenciales sobre el modelo y sus implicaciones

01

¿Qué aprendizaje desarrolló sobre cómo el modelo toma decisiones?

El modelo aprendió que el estrés es función de CONDICIONES LABORALES, no del individuo.

✅ Sí importa: horas trabajo ($r=0.60$, 27.1%), bugs/día (24.4%), reuniones (17.3%), sueño (11.7%)

❌ NO importa: edad ($r=0.006$, 0.43%), experiencia ($r=-0.020$, 0.32%), commits (0.11%)

→ Un senior con 15 años de experiencia puede tener estrés BAJO si trabaja jornadas razonables. La responsabilidad de intervención es de la ORGANIZACIÓN.

02

¿Hay alguna variable que tenga un peso excesivo?

daily_work_hours domina pero no monopoliza:

- Coeficientes Ridge: 27.1% del peso total
- Permutation Importance ($\Delta RMSE$): +10.31 pts (35.2% del impacto)

Las 3 variables top concentran el 68.8% del peso — distribución razonable.

Riesgo: Goodhart's Law. Si el developer sabe que sus horas son lo más importante, puede modificar lo que reporta sin cambiar su estrés real.

03

¿Qué pasaría si este modelo se implementa sin explicabilidad?

❌ SIN explicabilidad → Caja negra:
"El modelo predice estrés alto." — ¿Por qué?
Desconocido.

Sin detección de sesgos. Sin base para apelar. Riesgo legal LOPDP Ecuador.

✅ CON SHAP → Acción concreta:
"+23 pts: trabaja 13h/día | +19 pts: 12 bugs/día | -4 pts: hace ejercicio"
→ Intervención específica, trazable y auditable.

CONSIDERACIONES PARA MEJORAR EL MODELO

Cuatro líneas de mejora identificadas a partir del análisis del notebook

01

Variables de Contexto

- › Tipo de proyecto (legacy vs. nuevo)
- › Tamaño del equipo (solo vs. colaborativo)
- › Modalidad (remoto vs. presencial)
- › Claridad de requisitos del sprint

Capturar factores organizacionales que expliquen parte del 19% de varianza no capturada.

02

Dimensión Temporal

- › Estrés acumulado en semanas consecutivas
- › Modelos LSTM o Prophet para series temporales
- › Tendencias que Ridge no puede detectar
- › Alertas antes de que el burnout sea severo

El estrés puntual vs. estrés acumulado tienen distinto nivel de riesgo real.

03

Validación con Datos Reales

- › Dataset actual es SINTÉTICO (Kaggle)
- › Encuestas de bienestar real de empleados
- › Ajustar umbrales a percepción subjetiva real
- › Validar que $R^2=0.81$ se mantiene en producción

Un modelo entrenado en datos sintéticos puede no generalizar al mundo real.

04

Retroalimentación en Producción

- › Registrar resultado de cada intervención de RRHH
- › Aprender qué intervenciones son efectivas
- › Reentrenar cada 6 meses con datos reales
- › Monitorear RMSE en producción continuamente

Un modelo estático en un entorno dinámico pierde precisión inevitablemente.

CONCLUSIONES Y RECOMENDACIONES

Conclusiones

1. Ridge Regression ($\alpha=1.0$) logra $R^2=0.81$ con $RMSE=10.17$ pts — supera el baseline en 56.7%.

2. Gap train↔test de 0.50% — modelo sin overfitting, robusto y generalizable.

3. El estrés es determinado por condiciones laborales, no por perfil del desarrollador.

4. Equidad verificada: $\Delta RMSE \approx 1.03$ pts jornada y 0.48 pts edad (ambos < 3 pts).

5. 5 técnicas XAI con consistencia validada: SHAP, LIME ($R^2 \approx 0.07-0.59$), PDP, Coef., Perm. Imp.

Recomendaciones

Uso como alerta temprana, no como diagnóstico médico. Supervisión humana obligatoria en toda decisión.

Consentimiento informado de todos los empleados y comunicación transparente del propósito.

Reentrenamiento semestral y monitoreo del RMSE en producción para detectar degradación.

Añadir variables de contexto organizacional y dimensión temporal (LSTM/Prophet).

Validar con datos reales (no sintéticos) antes de cualquier despliegue productivo.

Predicción de Burnout en Desarrolladores

Calidad de Datos · Mitigación de Sesgos · Explicabilidad

Grupo 4

- › Eduardo Ceballos Jijón
- › Guillermo Granizo Veintimilla
- › José Ulloa Manzur
- › Christian Valle Maridueña