

Predicción de Burnout

en Desarrolladores de Software

Ridge Regression · XAI · Fairness · Ética en IA

Eduardo Ceballos Jijón

Guillermo Granizo Veintimilla

José Ulloa Manzur

Christian Valle Maridueña

UEES
Machine Learning
Grupo 4 · 2025

01 · Introducción del Problema

77%

desarrolladores reportan burnout (Stack Overflow 2023)

67%

reportan agotamiento severo que afecta productividad

10–40%

rotación anual en equipos con alto estrés

Pregunta de investigación: ¿Es posible predecir el nivel de estrés de un desarrollador a partir de métricas de comportamiento laboral, con suficiente precisión para guiar intervenciones preventivas?

- Tipo de problema: Regresión supervisada (target continuo 0–100)
- Dataset: 7,000 registros × 12 variables de comportamiento laboral
- Leakage detectado y eliminado: burnout_level = discretización exacta de stress_level

02 · Metodología: Flujo Obligatorio

1. Limpiar

Normalización categorías, 0 duplicados

2. Eliminar Leakage

Drop burnout_level: discretización determinística del target

3. Split 80/20

Stratify por rangos del target continuo

4. Imputar

SimpleImputer mean — fit solo en train

5. Encoding

No requerido (todas numéricas post-drop)

6. Scaling

StandardScaler — fit solo en train

Pipeline unificado: Winsorizer → SimpleImputer → StandardScaler → Ridge | Mismo objeto para CV, GridSearch, Fairness, SHAP y LIME

03 · Modelo Seleccionado y Evaluación

Ridge Regression

- Relaciones principalmente lineales ($r=0.60$ para `daily_work_hours`)
- Regularización L2 maneja multicolinealidad residual
- Coeficientes interpretables directamente (XAI exacto)
- GridSearchCV optimizó $\alpha=1.0$ sobre CV 5-fold

10.17 pts

RMSE test

0.8121

R^2 test

0.50%

Gap train/test

7.99 pts

MAE test

67.7%

% dentro ± 10 pts

56.7%

Mejora vs baseline

Sin overfitting confirmado: Gap = 0.50% (umbral: 15%) · 0 errores graves en clasificación de riesgo (Bajo↔Alto)

04 · Técnicas de Explicabilidad (XAI)

1. Coeficientes Ridge

Global · Exacto

Dirección e intensidad de cada variable. La variable dominante es `daily_work_hours` (27.1% de peso relativo).

2. Permutation Importance

Global · 30 rep.

Mide el aumento real del RMSE al eliminar cada variable. `daily_work_hours`: 35.23% del impacto total.

3. PDP

Global · Rango P5–P95

Muestra cómo evoluciona la predicción al variar una variable. `sleep_hours` tiene pendiente negativa clara.

4. SHAP

Global + Individual

Explicación matemáticamente exacta por instancia. Reproduce la predicción con error $< 10^{-12}$. Beeswarm + Waterfall.


5. LIME

Local · Fidelidad variable

Aproximación lineal local. R^2 local variable (0.07–0.59 en muestra analizada). Se contrasta con SHAP, que es exacto.

04b · SHAP: Explicación Individual — Perfil de Alto Estrés

¿Cómo llega el modelo a predecir `stress_level = 82`?



Lectura para RRHH

- Reuniones/carga → +12.7 pts (mayor factor)
- Bugs/calidad → +11.1 pts
- Trabajo + otros → +9.6 pts
- Sueño → factor protector → -5.1 pts

Intervención recomendada:

Revisar la carga asignada y reducir el número de reuniones diarias.

05 · Equidad Algorítmica y Mitigación de Sesgo

Equidad de error (Δ RMSE < 3 pts):  Jornada y Edad | Paridad demográfica:  Edad (DP=0.029) |  Jornada (DP=0.535, ver nota)

Variable sensible	Grupos	Δ RMSE entre grupos	DP Difference	Evaluación
Jornada laboral	Normal/Alta/Extrema	1.00 pts ✓	0.535 (*)	
Edad	Junior/Mid/Senior	0.54 pts ✓	0.029 ✓	

Mitigación activa: ablación de variable sensible (age)

RMSE: 10.17

Modelo completo
con age

RMSE: 10.16

Modelo sin age
sin age

-0.004 pts

Diferencia RMSE
cambio despreciable

MANTENER age

Decisión
sin sesgo real

(*) DP Difference jornada = 0.535: los grupos tienen estrés real muy distinto (Normal≈37pts vs Extrema≈70pts). La equidad de ERROR sí se cumple (Δ RMSE=1.0pt).

06 · Reflexión Ética y Riesgos del Sistema

 ALTO

Vigilancia encubierta

Sin consentimiento informado se vulnera la LOPDP y la autonomía del empleado.

 ALTO

Uso punitivo

Usar la predicción para sanciones en lugar de apoyo invierte el propósito del modelo.

 MEDIO

Falsa objetividad

El número (78/100) puede percibirse como certeza. El error real es ± 10 pts.

 MEDIO

Goodhart's Law

Si los devs conocen los pesos, manipularán las métricas para "parecer bien".

 CRÍTICO

Sin explicabilidad

Sin SHAP/LIME: opaco, inauditable, podría incumplir principios de transparencia.

07 · Conclusiones y Recomendaciones

✓ El modelo funciona

$R^2=0.81$, $RMSE=10.17$, sin overfitting (gap 0.50%). 67.7% de predicciones dentro de ± 10 pts. 0 errores graves (Bajo $\leftrightarrow$ Alto).

✓ Es explicable

5 técnicas XAI. SHAP reproduce exactamente la predicción. LIME complementa con análisis de fidelidad local.

✓ Es equitativo

$\Delta RMSE < 1$ pt entre grupos de jornada y edad. DP Difference < 0.10 . Ablación de age confirma ausencia de sesgo.

⚠ No está listo para producción sin controles

Consentimiento informado, supervisión humana, auditoría semestral y mecanismo de apelación son indispensables.

08 · Recomendaciones para Mejorar el Modelo

1. Variables de contexto

Tipo de proyecto, tamaño del equipo, modalidad de trabajo, cultura organizacional.

2. Dimensión temporal

Modelo de series temporales (LSTM o Ridge con features rezagadas) para capturar acumulación.

3. Validación real

Calibrar con encuestas MBI (Maslach Burnout Inventory) para verificar umbrales Bajo/Medio/Alto.

4. Retroalimentación

Pipeline de reentrenamiento cada 6 meses con datos nuevos etiquetados para evitar data drift.

Gracias

Por su atención

$R^2=0.81$

RMSE=10.17

5 técnicas XAI

Equidad ✓

Grupo 4 · UEES · Machine Learning · 2026

Eduardo Ceballos Jijón

Guillermo Granizo Veintimilla

José Ulloa Manzur

Christian Valle Maridueña